

Community detection based on unsupervised attributed network embedding

1. 论文出发点:

传统社区检测方法主要关注网络的拓扑结构，或只利用节点属性信息，但这些方法不能将两者信息充分结合，在无监督学习的场景中，很难同时捕获网络的高阶社区特征。并且还要求高的计算复杂度以及占用大量的存储空间。因此表示学习开始变得重要起来。

表示学习:

目标是将网络中的节点表示为低维向量，这些向量能够尽可能保留网络的结构特征和属性信息，避免了直接在高维的图结构上操作。核心思想是设计一个嵌入函数 $V \rightarrow R^d$ ，将节点集合 V 中的每个节点映射到一个 d 维向量，其中 $d \ll |V|$ 。该函数需要满足以下特性：嵌入后的节点表示应当能够保留节点间的连接关系，例如两个相连的节点在嵌入空间中的距离应尽可能接近；如果网络中的节点附带属性信息，如节点的文本特征或标签，则嵌入表示应当能够结合这些信息，以获得更丰富的节点表示。

网络表示学习主要有下面几种分类：

- 基于矩阵分解的方法：将网络的邻接矩阵或其它关联矩阵进行分解，得到节点的低维表示。

Spectral Embedding (谱嵌入)：利用拉普拉斯矩阵的特征值和特征向量，将网络节点嵌入到低维空间。缺点是计算开销大，不适合大规模网络。

LINE：通过保留网络中的一阶和二阶邻居信息，使用目标函数直接进行优化，使节点的向量嵌入保留原网络的局部和全局结构。

- 基于随机游走的方法：通过模拟随机游走过程，采集节点的邻域信息，生成伪序列，将节点表示学习问题转换为类似于自然语言处理中的词嵌入问题。

DeepWalk：通过在网络上进行随机游走生成节点序列，然后利用 Skip-Gram 模型将这些序列中的节点学习为低维向量。

node2vec：类似于 DeepWalk，但使用了更灵活的随机游走策略，通过参数控制游走的偏向性，从而更好地捕捉到不同尺度的网络特征。

- 基于深度学习的方法：

图卷积网络 (GCN)：GCN 通过卷积操作，将节点的邻居信息融合到自身表示中。通过多层卷积，可以捕获高阶邻居信息。例如，Graph Convolutional Networks (Kipf & Welling) 使用拉普拉斯矩阵进行归一化，实现图的卷积操作。

图自编码器 (Graph Auto-Encoder, GAE)：通过编码器-解码器结构，将节点表示为低维向量，解码器则尝试重构网络的邻接矩阵。这样，编码器学习到的表示能够保留网络的结构信息。例如，Variational Graph Auto-Encoder (VGAE) 进一步引入了变分推断的方法，使得嵌入表示更加稳健。

图注意力网络 (Graph Attention Networks, GAT)：使用注意力机制，计算节点与其邻居节点的加权连接，从而使节点表示能够自适应地聚合邻居信息。GAT 可以学习到每条边的重要性，从而更好地捕捉节点之间的关系。

网络表示学习的优化目标：尽可能地保留网络结构信息和节点属性信息。以损失函数的形式来实现：

- 结构重构损失**：通过最小化嵌入节点间的距离与原网络连接关系的差异，保持网络结构。例如，如果 u 和 v 是连接的，则希望它们的嵌入表示 z_u 和 z_v 之间的距离小。

$$L_{\text{structure}} = - \sum \log(\sigma(\mathbf{z}_u^T \mathbf{z}_v)) \quad (1)$$

$$\sum_{(u,v) \in E}$$

- **属性重构损失**: 通过重构节点属性, 使嵌入表示能够保留原有的节点特征。

$$L_{\text{attribute}} = \sum_{i=1}^N \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 \quad (2)$$

2. 模型构建:




Fig. 1. The framework of the CDBNE model.

该模型分为三个部分, 第一部分为GAE, 第二部分为模块度最大化模块, 最后一部分为自训练聚类模块

GAE: 通过自编码器和解码器重构属性矩阵

$$L_R = \frac{1}{N} \sum_{i=1}^N \left[\|X_i - \hat{X}_i\|_2^2 + \gamma \sum_{j \in N_i} \phi(z_i^T z_j) \right] \quad (3)$$

节点属性重构损失和拓扑结构重构损失的加权和

模块度:

$$Q = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j) \quad (4)$$

模块度衡量的是实际观察到的社区结构与随机情况下社区结构的对比。具体来说:

A_{ij} 表示实际的连接关系。如果 A_{ij} 为 1, 意味着节点 i 和 j 在实际中是相连的。 $k_i k_j / 2m$ 表示在随机情况下节点 i 和 j 相连的概率。这个值的由来可以通过假设网络中的边是随机连接的, 节点 i 和 j 的连接概率取决于它们的度数。设想一个随机图模型, 其中网络的每一条边都是在保持每个节点的度数 k_i 不变的前提下随机重连的。在这个模型中, 两个节点 i 和 j 之间有 k_i 条“出边”连接机会, 而随机情况下, 它们相连的概率为:

$$P_{\text{rand}}(i, j) = \frac{k_i k_j}{2m} \quad (5)$$

为了简化计算, 模块度 Q 也可以表示为矩阵形式。

$$B_{ij} = A_{ij} - \frac{k_i k_j}{2m} \quad (6)$$

$$Q = \frac{1}{2m} \text{Tr}(H^T B H)$$

H 是一个 $N \times C$ 的社区指示矩阵, 如果节点 i 属于社区 c , 则 $H_{ic}=1$, 否则为 0. Tr 表示矩阵的迹 (即对角线元素的和)。

模块度的核心思想是: 如果节点 i 和 j 属于相同社区, 并且它们之间有更多的边连接, 且这种连接远超过随机情况下的期望值, 那么这个社区划分的模块度会更高。

在本文中, 提出了一种松弛的方式, 即允许 H 变为连续值表示。定义一个新的松弛矩阵 $H^\wedge$, 如下:

$$L_M = \frac{1}{4m} Tr(\hat{H}^T B \hat{H}) \text{ with } \hat{H} = softmax(ZC). \quad (7)$$

KL散度:

$$L_C = KL(P \parallel Q) = \sum_i \sum_u p_{iu} \log \left(\frac{p_{iu}}{q_{iu}} \right) \quad (8)$$

p_{iu} 表示节点 v_i 属于社区 u 的真实概率, 而 q_{iu} 表示预测概率。在无监督的社区检测中, 预测分布 Q 是通过学生的 t 分布 (Student's t -distribution) 来计算的。该分布用于衡量节点 v 与社区中心 u 之间的相似度, 具体公式为:

$$q_{iu} = \frac{(1 + \|z_i - \mu_u\|^2 / \alpha)^{-\frac{\alpha+1}{2}}}{\sum_k (1 + \|z_i - \mu_k\|^2 / \alpha)^{-\frac{\alpha+1}{2}}} \quad (9)$$

z_i : 节点 v_i 的嵌入向量。 μ_u : 社区 u 的中心向量 (聚类中心)。 α : 自由度, 控制 t 分布的形状。在文章的实验中, α 通常被设置为 1。

通过 K-means 聚类初始化每个社区的中心向量 μ_u 。

通过计算节点嵌入向量 z_i 与社区中心向量 μ_u 之间的欧氏距离, 并使用 t 分布计算相似度, 得到预测概率分布 Q 。

真实分布 P 的计算是基于预测分布 Q 来的, 目的是使更“确信”的分配对学习过程影响更大, 对每个社区 μ , 平方其预测概率 q_{iu} 以放大高置信度的概率

3. 数据集:

Statistics of datasets.

Dataset	Nodes	Edges	Features	Communities
Cora	2,708	5,429	1,433	7
Citeseer	3,327	4,732	3,703	6
Pubmed	19,717	44,338	500	3

4. 结果:

The performance of CDBNE and competitors on community detection task.

Methods	Info	Cora			Citeseer			Pubmed		
		ACC	NMI	ARI	ACC	NMI	ARI	ACC	NMI	ARI
K-means	X	0.500	0.547	0.501	0.544	0.312	0.285	0.580	0.278	0.246
Graph Encoder	A	0.301	0.059	0.046	0.293	0.057	0.043	0.531	0.210	0.184
DeepWalk	A	0.529	0.384	0.291	0.390	0.131	0.137	0.647	0.238	0.255
TADW	A&X	0.536	0.366	0.240	0.529	0.320	0.286	0.565	0.224	0.177
GAE	A&X	0.530	0.397	0.293	0.380	0.174	0.141	0.632	0.249	0.246
VGAE	A&X	0.592	0.408	0.347	0.392	0.163	0.101	0.619	0.216	0.201
MGAE	A&X	0.684	0.511	0.448	0.661	0.412	0.414	0.593	0.282	0.248
ARGA	A&X	0.640	0.449	0.352	0.573	0.350	0.341	0.681	0.276	0.291
ARVGA	A&X	0.638	0.450	0.374	0.544	0.261	0.245	0.513	0.117	0.078
DAEGC	A&X	0.704	0.528	0.496	0.672	0.397	0.410	0.671	0.266	0.278
GATE	A&X	0.658	0.527	0.451	0.616	0.401	0.381	0.673	0.322	0.299
ARVGA-AX	A&X	0.711	0.526	0.495	0.581	0.338	0.301	0.640	0.239	0.226
SENet	A&X	0.719	0.550	0.490	0.675	0.417	0.424	0.676	0.306	0.297
CDBNE	A&X	0.728	0.537	0.513	0.697	0.438	0.455	0.707	0.336	0.337

