

Revisiting Modularity Maximization for Graph Clustering: A Contrastive Learning Perspective(Magi)

1. 论文背景:

图对比学习大量依赖数据增强, 在处理大规模图时, 计算开销过大, 不易扩展, 并且使用图增强技术生成的伪标签有可能导致节点之间的语义漂移, 影响聚类效果。因此本文提出了一种将模块度最大化与图对比学习相结合的方法, 利用模块度矩阵自然定义的正负样本对, 形成一种不依赖于图增强的新框架。

2. 模块度定义:

$$Q = \frac{1}{2m} \sum_{i,j} (A_{i,j} - \frac{d_i d_j}{2m}) \delta(c_i, c_j),$$

其中d代表每个节点的度, m是节点的数量, δ 代表两个节点是否属于同一个社区, 是则为1, 否则为0. 模块度Q反映了图的实际连接模式与随机连接模式之间的差异, Q值越大, 表示节点划分的社区内部连接更加紧密。

模块度矩阵定义:

$$B_{u,v} = A_{u,v} - \frac{k_u k_v}{2m}$$

模块度矩阵为正, 表示节点连接比随机情况更紧密, 反之则更稀疏。后面这部分称之为配置模型, 是假设没有社区结构的情况下, 节点之间随机连接时的期望连接数。


3. 模块度与对比学习相关联:

有了模块度矩阵, 模块度的定义就可以改为

$$Q = \frac{1}{2m} \left(\sum_{(u,v) \in M^+} B_{u,v} - \sum_{(u,v) \in M^-} B_{u,v} \right)$$

正样本对和负样本对之和, 最大化模块度就变成了最大化正样本对模块度值, 最小化负样本对的值。这样它的目标就和对比学习的一致了, 两者便联系起来了。

4. 训练数据:



为了在小批次内实现有效的模块度优化，Magi引入了两阶段的随机游走来生成高效的小批次子社区。这种方法能捕捉图中的高阶邻近性，使得学习的节点表示更符合社区结构。

第一阶段：采样子社区

- 从图中随机选择若干个根节点，假设为 v 。
- 对于每个根节点 v ，执行多次随机游走，每次游走的长度为 l ，这些游走能够访问到一些与 v 社区结构相关的节点。
- 将访问到的节点及其访问次数记录下来。我们假设这些访问次数超过平均值的节点，属于与根节点 v 同一个社区，从而近似地得到一个子社区 O 。
- 对于多个根节点，重复上述操作，最终合并成一个训练小批次 B 。

第二阶段：生成相似性矩阵 S

- 在生成的子社区 B 内再次进行随机游走，记录每个节点对之间的访问次数，从而构建相似性矩阵 S 。
- S 表示节点 u 和 v 在子社区内的访问概率，即表示它们的相似性：

$$S_{v,u} = \frac{t_{v,u}^2}{\sum_{u' \in B} t_{v,u'}^2}$$

t 是节点 u 到 v 的访问次数

计算小批次的模块度矩阵

- 在得到相似性矩阵 S 后，Magi利用配置模型计算节点对的期望连接，从而得到小批次的模块度矩阵 B ：

$$B_{u,v} = S_{u,v} - \frac{1}{|B|}$$


分母代表小批次的节点数

5. 对比学习：

模型的选取：文中选了两种模型，一种是GCN，主要用于小范围的数据集，另一种是GrapgSAGE，主要用于大范围的图。

通过模块度矩阵得到正负样本后，通过gcn等得到嵌入z，进行对比学习：

$$\mathcal{L}_{SimCLR}(v) = - \sum_{u \in \mathcal{M}_v^+} \log \frac{\exp(z_v \cdot z_u / \tau)}{\sum_{u \in \mathcal{M}_v^+} \exp(z_v \cdot z_u / \tau) + \sum_{u' \in \mathcal{M}_v^-} \exp(z_v \cdot z_{u'} / \tau)}$$



6. 数据集选取：

Dataset	# Nodes	# Edges	# Features	# Clusters
Cora	2,708	5,278	1,433	7
CiteSeer	3,327	4,614	3,703	6
Amazon-Photo	7,650	119,081	745	8
Amazon-Computers	13,752	491,722	767	10
ogbn-arxiv	169,343	1,166,243	128	40
Reddit	232,965	23,213,838	602	41
ogbn-products	2,449,029	61,859,140	100	47
ogbn-papers100M	111,059,956	1,615,685,872	128	172

7. 总结：

两步随机游走类似于pp，有些相似，可以学习的点有对比学习。可不可以两个视角得到后在求个模块度，每个视角里面又分为两对正负样本，然后再互相对比学习。